Created	@11 décembre 2025 18:36
Author	

C'est l'étape la plus **critique** du projet. Un bon moteur de recherche et un Chatbot IA efficace dépendent entièrement de la qualité de la structuration de vos données. L'objectif est de transformer les documents non structurés (PDF, DOC) en un format **JSON structuré et catégorisé** qui sera ensuite indexé.

Voici une méthodologie étape par étape sur la manière de structurer vos données, en prenant en compte les quatre sources principales fournies :

🏗️ Méthodologie de Structuration des Données

Phase 1 : Définition des Schémas de Données

Vous devez créer trois schémas de données principaux pour représenter les trois types d'informations clés : les Offres, les Conventions, et le Guide Opérationnel (NGBSS).

1. Schéma des Offres Commerciales (Clé pour la Recommandation et le Filtre)

Ce schéma doit contenir tous les champs nécessaires pour le filtrage avancé (Phase 2) et la recommandation automatique (Phase 3).

Champ (Clé JSON)	Type	Rôle / Utilisation
`offre_id`	String	Identifiant unique.
`nom_offre`	String	Nom complet de l'offre (Recherche par mots-clés).
`secteur_activite`	String (Keyword)	Le secteur ciblé (PME, Administration, Éducation, etc.). **Filtre dynamique essentiel.**
`type_offre`	String (Keyword)	Type de service (Fibre, Data, Cloud, Voix). **Filtre dynamique.**
`description_courte`	String	Résumé de l'offre (Pour les cartes visuelles).
`conditions_eligibilite`	String	Description des clients éligibles (Clé pour la Recommandation IA).

`restrictions_geographiques`	`String`	Le cas échéant.
`date_debut_validite`	`Date`	Pour le filtre de période de validité.
`date_fin_validite`	`Date`	Pour le filtre de période de validité.
`id_convention_associee`	`String`	Le lien vers le document de convention. **Clé pour la consultation rapide.**
`source_pdf_url`	`String`	Lien vers le document PDF original (Pour le téléchargement).

2. Schéma des Conventions Signées

Champ (Clé JSON)	Type	Rôle / Utilisation
`convention_id`	`String`	Identifiant unique (correspondant à `id_convention_associee`).
`nom_partenaire`	`String` (Keyword)	Le nom de l'entreprise ou de l'administration partenaire. **Filtre dynamique essentiel.**
`date_signature`	`Date`	
`resume_clauses`	`String`	Les clauses principales du partenariat (utile pour le Chatbot).
`portee_secteur`	`String` (Keyword)	Le secteur concerné par la convention.
`source_pdf_url`	`String`	Lien vers le document PDF original (Téléchargement).

3. Schéma du Guide NGBSS (Clé pour le Chatbot d'Assistance)

Ce schéma doit être optimisé pour la recherche conversationnelle et les instructions.

Champ (Clé JSON)	Type	Rôle / Utilisation
`etape_id`	`String`	ID unique (ex: "NGBSS-05-3").
`titre_operation`	`String`	(ex: "Création d'un compte client B2B").
`instructions_detaillees`	`String`	Le texte complet de l'étape.
`mots_cles_operation`	`List<String>` (Keyword)	Mots-clés pour la recherche rapide.

illustration_textuelle	String	Le texte extrait de l'image via OCR (Bonus spécial).

Phase 2 : Processus de Transformation (Python)

Vous utilisez des scripts Python pour extraire et remplir ces schémas.

1. Extraction (Extraction)

- Utilisez `pdfminer.six` ou `PyMuPDF` pour obtenir le texte brut de chaque document.
- **Implémentation du Bonus :** Pour le Guide NGBSS, utilisez `Tesseract OCR` sur les images.

2. Nettoyage et Normalisation (Transformation)

- **Nettoyage du Texte :** Suppression des en-têtes/pieds de page, des numéros, et des caractères spéciaux.
- **Normalisation des Catégories :** Assurez-vous que les secteurs d'activité ou les types d'offres sont toujours écrits de la même manière (ex: "PME" et non "Petites et Moyennes Entreprises").

3. Remplissage des Champs (Chargement)

C'est souvent l'étape la plus manuelle et heuristique pour un hackathon :

- **Extraction par Patrons :** Utilisez des expressions régulières (`re` en Python) pour identifier des phrases clés et remplir les champs.
  - Ex: Chercher les phrases commençant par "Cette offre est valide du..." pour remplir les champs `date_debut_validite` et `date_fin_validite`.
  - Ex: Chercher les sections titrées "Conditions d'éligibilité :" pour remplir le champ `conditions_eligibilite`.
- **Catégorisation :** Si la catégorisation n'est pas explicite, utilisez des listes de mots-clés ou un petit modèle de classification pour attribuer le `secteur_activite` et le `type_offre`.

Phase 3 : Utilisation des Données Structurées

- **Indexation Elasticsearch :** Les schémas 1 et 2 sont envoyés à Elasticsearch pour le moteur de recherche avancé (Filtres et Mots-Clés).
- **Vectorisation RAG :** Les schémas 1, 2 et 3 sont vectorisés (transformés en embeddings) et stockés dans ChromaDB pour le Chatbot IA (Recherche Conversationnelle et Assistance NGBSS).